

# 华东师范大学

East China Normal University

## 学位论文开题报告登记表

### Graduate Thesis/Dissertation Proposal Application Form

论文题目

Thesis/Dissertation Title

面向语法纠错的可解释性与鲁棒性优化研究

学号

Student No.

51275903082

姓名

Student Name

王千予

学生类别

Graduate Degree Category

☐ 学术学位博士生 Academic Doctoral Program

☐ 专业学位博士生 Professional Doctoral Program

☐ 学术学位硕士生 Academic Master's Program

☒ 专业学位硕士生 Professional Master's Program

学习形式

Mode of Study

☒ 全日制 Full-time

☐ 非全日制 Part-time

导师（组）

Supervisor/Committee

兰韵诗 副教授

专业/领域

Major/Field of Study

数据科学与工程

培养单位

School/Department

数据科学与工程学院

## 1、选题的研究意义及国内外研究现状综述，附参考文献。

Significance of the research topic, overview of the current research status (domestic and international), with references.

### 一、研究意义

语法错误纠正 (Grammatical Error Correction, GEC) 旨在自动识别并修正英文文本中的拼写、词汇、搭配、形态、句法及语义表达等错误，并在尽量保持原意、遵循最小修改原则的基础上生成规范文本。该技术可应用于英语写作辅助、自动作文评价、二语学习反馈、办公文本校对和人机交互等场景<sup>[1][2][3]</sup>。近年来，序列到序列、序列到编辑以及大语言模型等方法不断提升 GEC 系统在标准评测中的纠错性能<sup>[4][5][6]</sup>。然而，真实英文写作中的输入往往包含更长上下文、多样话题背景和灵活表达方式，模型仍可能受到错误无关上下文的影响，出现纠错结果不稳定、漏纠、误纠、过度纠错以及修改依据不清晰等问题<sup>[7][8][9]</sup>。

本研究从鲁棒性与可解释性两个方面研究 GEC 系统。鲁棒性关注在原始语法错误及其有效纠正方式保持不变、而错误无关上下文发生变化时，模型能否保持稳定的纠正结果；可解释性关注模型能否围绕具体修改说明错误位置、错误类型、修改方式及其语言依据。二者共同影响 GEC 系统输出的可用性：如果模型在上下文变化下产生不一致纠正，用户难以判断修改建议是否稳定可靠；如果系统只给出修改结果而缺少清晰解释，学习者也难以理解错误原因和相关语言规则。基于此，本研究重点关注上下文反事实鲁棒性、编辑级错误分析以及纠正—解释一致性校验，具有以下重要意义：

1. **面向真实英文写作场景，提升 GEC 反馈的可用性。**真实写作中的句子通常处于具体上下文中，用户也往往需要理解模型为何作出某处修改。本研究关注纠错结果是否稳定、解释是否对应具体修改，有助于提升 GEC 系统在实际写作辅助场景中的可用性。
2. **面向错误无关上下文变化引发的纠错不一致问题，提升 GEC 系统的上下文鲁棒性。**真实写作数据往往比标准评测数据包含更长上下文和更灵活的表达方式，模型可能受到错误无关上下文变化的影响，从而对同一语法错误作出不一致判断<sup>[8][9]</sup>。本研究基于 CoCoGEC 框架构造句内和句间上下文反事实样本，在不改变原始错误及其有效纠正方式的前提下，分析并减少无关上下文对模型的干扰，有助于提升纠错结果在真实语境中的稳定性<sup>[11]</sup>。
3. **面向模型实际修改与解释一致性，推动 GEC 评价从整体分数走向编辑级可解释分析。**传统 F0.5 等指标只能反映系统整体纠错性能，难以说明模型具体在哪些位置改对、改错、漏改或过度纠错<sup>[2][3][17]</sup>，也难以判断生成解释是否真正对应实际修改<sup>[15][16][23][24]</sup>。为此，本研究将模型输出拆解为具体编辑，逐条分析其修改结果和错误类型；同时检查自然语言解释是否与对应编辑在修改位置、修改方向、错误类型及语法依据上保持一致，从而增强 GEC 系统反馈的透明度、可追溯性和可核验性。

## 二、国内外研究现状综述

### 2.1 语法错误纠正研究

语法错误纠正 (GEC) 经历了规则方法、统计机器翻译、神经序列生成、预训练语言模型和大语言模型等发展阶段<sup>[1]</sup>。CoNLL-2014、BEA-2019 等共享任务推动了 GEC 数据集、评

价指标和系统方法的发展<sup>[2][3]</sup>。现有方法主要包括序列到序列方法和序列到编辑方法：前者将纠错视为从错误文本到规范文本的生成过程，能够处理插入、删除、替换和语序调整等编辑<sup>[4][6]</sup>；后者直接预测局部编辑操作，具有推理效率高、最小修改性较强等特点，GECToR 是其中的代表性模型<sup>[5]</sup>。近年来，大语言模型在 GEC 中展现出较强的泛化能力，但也容易因自由生成方式产生过度润色或不必要改写<sup>[7]</sup>。因此，GEC 研究逐渐从单纯提升标准测试集得分，扩展到鲁棒性、可控性、可解释性和教育反馈质量等问题<sup>[8][13][15][20][21]</sup>。

## 2.2 鲁棒性与上下文反事实研究

鲁棒性是 GEC 系统真实应用中的重要问题。RobustGEC 表明，即使目标语法错误不变，仅改变错误无关上下文，也可能导致模型输出发生明显变化<sup>[8]</sup>。上下文数据增强研究进一步说明，为相同错误模式构造新的语言环境能够改善模型泛化能力，但样本的自然性、标签有效性和训练价值仍然会影响方法效果<sup>[9]</sup>。反事实数据增强通过对输入进行受控修改，促使模型减少对偶然表层关联的依赖。DISCO 等工作利用大语言模型生成和筛选反事实样本，在分类任务中取得了较好效果<sup>[10]</sup>。但 GEC 输出通常由多个编辑构成，传统“标签翻转”式反事实定义难以直接适用。CoCoGEC 针对 GEC 任务提出句内与句间上下文反事实生成、编辑过滤和 GEC 互信息筛选机制，以保持原始编辑有效，并筛选能够暴露模型上下文依赖的困难样本<sup>[11]</sup>。

## 2.3 可解释语法纠错与编辑级错误分析研究

可解释 GEC 关注系统是否能够说明修改原因、错误类型和语言依据。ERRANT 通过自动提取和分类编辑，为 GEC 系统的细粒度评价提供了基础<sup>[12]</sup>。示例型解释、EXPECT、GEE 和 Prompt Insertion 等研究从不同角度探索了语法错误解释生成，说明解释能够帮助学习者理解修改依据，并提升反馈的可理解性<sup>[13][14][15][16]</sup>。近年来，相关研究进一步关注编辑级错误分析和错误模式表示。CLEME2.0 将 GEC 输出分解为正确纠正、错误纠正、漏纠和过度纠正等类型，为系统错误来源分析提供了更细粒度的视角<sup>[17]</sup>。Explanation-based Retrieval、Encode Errors 和编辑归因研究则表明，解释、错误表示和具体编辑可以用于辅助示例选择或提升评价指标的可解释性<sup>[18][19][22]</sup>。此外，EXCGEC 和 EXGEC 从“纠正与解释结合”的角度构建可解释 GEC 任务或框架，强调解释应当与具体纠正编辑相对应<sup>[23][24]</sup>。

## 参考文献

- [1] Bryant, Christopher, et al. "Grammatical error correction: A survey of the state of the art." *Computational Linguistics* (2023): 643-701.
- [2] Ng, Hwee Tou, et al. "The CoNLL-2014 shared task on grammatical error correction." *Proceedings of the eighteenth conference on computational natural language learning: shared task*. 2014.
- [3] Bryant, Christopher, et al. "The BEA-2019 shared task on grammatical error correction." *Proceedings of the fourteenth workshop on innovative use of NLP for building educational applications*. 2019.
- [4] Junczys-Dowmunt, Marcin, et al. "Approaching neural grammatical error correction as a low-resource machine translation task." *Proceedings of the 2018 Conference of the North American Chapter of the Association for Computational Linguistics: Human Language Technologies, Volume 1 (Long Papers)*. 2018.
- [5] Omelianchuk, Kostiantyn, et al. "GECToR – grammatical error correction: Tag, not rewrite." *Proceedings of the fifteenth workshop on innovative use of NLP for building educational applications*. 2020.

- [6] Rothe, Sascha, et al. "A simple recipe for multilingual grammatical error correction." Proceedings of the 59th Annual Meeting of the Association for Computational Linguistics and the 11th International Joint Conference on Natural Language Processing (Volume 2: Short Papers). 2021.
- [7] Loem, Mengsay, et al. "Exploring effectiveness of GPT-3 in grammatical error correction: A study on performance and controllability in prompt-based methods." Proceedings of the 18th workshop on innovative use of NLP for building educational applications (BEA 2023). 2023.
- [8] Zhang, Yue, et al. "RobustGEC: Robust grammatical error correction against subtle context perturbation." Proceedings of the 2023 Conference on Empirical Methods in Natural Language Processing. 2023.
- [9] Wang, Yixuan, et al. "Improving grammatical error correction via contextual data augmentation." Findings of the Association for Computational Linguistics: ACL 2024. 2024.
- [10] Chen, Zeming, et al. "DISCO: Distilling counterfactuals with large language models." Proceedings of the 61st Annual Meeting of the Association for Computational Linguistics (Volume 1: Long Papers). 2023.
- [11] Wang, Qianyu, et al. "CoCoGEC: Counterfactual Generation for Robust Grammatical Error Correction." arXiv preprint arXiv:2606.15069 (2026).
- [12] Bryant, Christopher, Mariano Felice, and Ted Briscoe. "Automatic annotation and evaluation of error types for grammatical error correction." Proceedings of the 55th annual meeting of the association for computational linguistics (Volume 1: Long Papers). 2017.
- [13] Kaneko, Masahiro, et al. "Interpretability for language learners using example-based grammatical error correction." Proceedings of the 60th Annual Meeting of the Association for Computational Linguistics (Volume 1: Long Papers). 2022.
- [14] Fei, Yuejiao, et al. "Enhancing grammatical error correction systems with explanations." Proceedings of the 61st Annual Meeting of the Association for Computational Linguistics (Volume 1: Long Papers). 2023.
- [15] Song, Yixiao, et al. "GEE! grammar error explanation with large language models." Findings of the Association for Computational Linguistics: NAACL 2024. 2024.
- [16] Kaneko, Masahiro, and Naoaki Okazaki. "Controlled generation with prompt insertion for natural language explanations in grammatical error correction." Proceedings of the 2024 Joint International Conference on Computational Linguistics, Language Resources and Evaluation (LREC-COLING 2024). 2024.
- [17] Ye, Jingheng, et al. "CLEME2. 0: Towards Interpretable Evaluation by Disentangling Edits for Grammatical Error Correction." Proceedings of the 63rd Annual Meeting of the Association for Computational Linguistics (Volume 1: Long Papers). 2025.
- [18] Li, Wei, et al. "Explanation based in-context demonstrations retrieval for multilingual grammatical error correction." Proceedings of the 2025 Conference of the Nations of the Americas Chapter of the Association for Computational Linguistics: Human Language Technologies (Volume 1: Long Papers). 2025.
- [19] Peng, Guangyue, et al. "Encode Errors: Representational Retrieval of In-Context Demonstrations for Multilingual Grammatical Error Correction." Findings of the Association for Computational Linguistics: ACL 2025. 2025.
- [20] Koyama, Aomi, et al. "Targeted Syntactic Evaluation for Grammatical Error Correction." Proceedings of the 63rd Annual Meeting of the Association for Computational Linguistics (Volume 1: Long Papers). 2025.
- [21] Cao, Yayu, et al. "CxGGEC: Construction-Guided Grammatical Error Correction." Proceedings of the 63rd Annual Meeting of the Association for Computational Linguistics (Volume 1: Long Papers). 2025.

- [22] Goto, Takumi, Justin Vasselli, and Taro Watanabe. "Improving explainability of sentence-level metrics via edit-level attribution for grammatical error correction." Proceedings of the 63rd Annual Meeting of the Association for Computational Linguistics (Volume 4: Student Research Workshop). 2025.
- [23] Ye, Jingheng, et al. "EXCGYe, Jingheng, et al. "EXCGEC: A Benchmark for Edit-Wise Explainable Chinese Grammatical Error Correction." Proceedings of the AAAI Conference on Artificial Intelligence. Vol. 39. No. 24. 2025.
- [24] Ye, Jingheng, et al. "Corrections meet explanations: A unified framework for explainable grammatical error correction." arXiv preprint arXiv:2502.15261 (2025).

## 2、研究目标、研究内容和拟解决的关键问题。

Research objectives, main content and key issues to be addressed.

### 一、研究目标

本研究面向英文语法错误纠正系统在真实写作场景中存在的上下文敏感、漏纠误纠、过度纠错以及修改依据不清晰等问题，围绕鲁棒性与可解释性两个方面开展研究。总体目标是在保持纠错准确性的基础上，提升模型在错误无关上下文变化下的纠正稳定性，并使模型实际产生的纠正编辑能够被细粒度分析、解释和校验。具体目标如下：

1. 构建面向错误无关上下文变化的 GEC 鲁棒性分析方法。针对真实写作中句内成分变化和句间上下文扩展可能导致纠错结果不一致的问题，分析不同 GEC 模型在词级扰动、句级上下文扩展等场景下的输出变化，建立用于衡量模型上下文稳定性的评价方法。

2. 基于 CoCoGEC 构建上下文反事实样本生成与筛选方法。通过构造句内和句间上下文反事实样本，在保持原始语法错误及其有效纠正方式不变前提下，结合编辑一致性过滤和困难样本筛选，减少错误无关上下文对模型纠错结果的干扰，提升模型在复杂语境中的稳定性。

3. 构建面向模型实际输出编辑的编辑级错误分析与解释一致性校验方法。将模型输出拆解为具体编辑，逐条分析模型在哪些位置改对、改错、漏改或过度纠错，并进一步生成对应的自然语言解释；同时校验解释是否与实际编辑在修改位置、修改方向、错误类型及语法依据上保持一致，从而提升 GEC 系统反馈的透明度、可追溯性和可验证性。

### 二、研究内容

#### 2.1 任务定义

本研究首先明确 GEC 在真实写作场景下的两个核心问题：一是模型在错误无关上下文变化下能否保持稳定纠错，二是模型实际产生的修改能否被分析、解释和校验。围绕上述问题，本文从纠错准确性、上下文稳定性、编辑级错误分析和解释一致性校验等方面评估模型表现。

#### 2.2 基于上下文反事实生成的 GEC 鲁棒性分析与优化

本研究将基于 CoCoGEC 框架，分析并缓解 GEC 模型对错误无关上下文的敏感性。具体而言，通过构造句内和句间上下文反事实样本，在保持原始语法错误及其有效纠正方式不变的前提下，改变非错误词语、短语或句间上下文，并结合编辑一致性过滤和困难样本筛选，

获得能够暴露模型上下文依赖的训练样本，从而提升模型在复杂语境中的纠错稳定性。

**2.3 面向模型输出编辑的编辑级错误分析与解释一致性校验**

本研究将模型输出拆解为具体编辑，逐条分析模型在哪些位置改对、改错、漏改或进行了不必要修改，并进一步为具体编辑生成自然语言解释。解释内容需要说明错误位置、修改方向、错误类型和语法依据。为检验解释是否真实对应模型实际修改，本文将提出“解释到编辑的反向重构校验”方法，考察解释能否反推出对应编辑的位置、修改方向和错误类型，从而识别解释错位、解释泛化或语法依据不准确等问题。

**三、拟解决的关键问题**

**3.1 如何明确 GEC 鲁棒性与可解释性的研究对象和评价方式**

现有 GEC 评价主要依赖 F0.5 等整体指标，能够反映模型总体纠错效果，但难以说明模型在错误无关上下文变化下是否保持稳定，也难以展示模型每一处修改是否合理。因此，本研究首先需要明确两个问题：一是如何评价模型在上下文变化前后的纠错一致性；二是如何分析模型具体改了些什么、改得是否正确，以及解释是否对应实际修改。

**3.2 如何构造有效的上下文反事实样本以提升模型纠错稳定性**

真实英文写作中，同一个语法错误可能出现在不同上下文环境中，模型容易受到错误无关上下文的影响，产生不一致的纠错结果。因此，本研究需要解决如何在不改变原始语法错误及其有效纠正方式的前提下，构造自然、有效且具有训练价值的句内和句间上下文反事实样本，并通过编辑一致性过滤和困难样本筛选，减少模型对无关上下文的依赖，提升纠错结果的稳定性。

**3.3 如何分析模型实际修改并校验解释是否对应修改**

现有可解释 GEC 研究多关注解释生成本身，但生成解释可能出现解释位置不对、解释内容过于笼统或语法依据不准确等问题。因此，本研究需要解决如何将模型输出拆解为具体编辑，分析模型在哪些地方改对、改错、漏改或过度纠错，并进一步校验自然语言解释是否与实际修改在修改位置、修改方向、错误类型和语法依据上保持一致，从而提升 GEC 系统反馈的透明度和可信度。

3、拟采取的研究方法、技术路线、实验方案及其可行性分析。（研究方法涉及到人体或动物实验的，需首先进行伦理审查，审查通过后，须将人体、动物实验伦理审查意见作为开题报告的一部分，并同时附伦理审查通过批准函）

Proposed research methods, technical approach, experimental design and feasibility analysis.

**一、拟采取的研究方法**

**1.1 文献研究与任务定义**

广泛阅读英文语法错误纠正、上下文鲁棒性、反事实数据增强、编辑级错误分析和语法错误解释等方向的相关研究，梳理该领域的主要技术路线与现有不足。在此基础上，明确本研究两个核心问题：一是模型在错误无关上下文变化下能否保持稳定纠错，二是模型产生的具体修改能否被分析、解释和校验。围绕上述问题，进一步确定鲁棒性评价、编辑级错误分析和解释一致性校验的基本任务定义与评价指标。

## 1.2 反事实样本构建方法

针对 GEC 模型容易受到错误无关上下文影响的问题，本研究基于 CoCoGEC 框架构造句内和句间两类上下文反事实样本。句内层面对不影响目标错误的词语或短语进行受控改写，句间层面在目标句前后补充语义连贯、语法正确的上下文，并通过编辑一致性比较、语法检查和困难样本筛选保证样本质量，为后续鲁棒性训练与评估提供数据基础。

## 1.3 编辑级错误分析与解释一致性校验

针对 GEC 系统只给出最终修改结果、缺少具体修改依据的问题，本研究将模型输出拆解为一条条具体编辑，并与参考编辑进行对齐，分析模型在哪些位置改对、改错、漏改或进行了不必要修改。在此基础上，为每处具体修改生成自然语言解释，说明错误位置、修改方向、错误类型和语法依据。进一步提出“解释到编辑”的反向重构校验方法，即根据原句和解释反推出应发生的修改，并与模型实际编辑进行比较，以判断解释是否真正对应具体修改。

# 二、技术路线

## 2.1 文献调研与任务建模

调研英文语法错误纠正、上下文鲁棒性、反事实数据增强、编辑级错误分析和语法错误解释等相关研究，结合 CoCoGEC 已有工作，将本研究建模为“纠错输出一上下文反事实扰动—编辑级错误分析—解释一致性校验”的过程。其中，鲁棒性部分关注模型在错误无关上下文变化前后是否保持稳定纠错；可解释性部分关注模型具体改了什么、改得是否正确，以及生成解释是否真正对应实际修改。

## 2.2 基于 CoCoGEC 的上下文反事实鲁棒性方法设计

基于 CoCoGEC 框架构造句内和句间两类上下文反事实样本。句内层面，对不影响目标错误的词语或短语进行插入、替换和删除；句间层面，在目标句前后加入语义连贯、语法正确的上下文。样本构造后，通过编辑一致性比较、错误跨度检查和语法检查过滤无效样本，保证原始语法错误及其有效纠正方式不被改变。随后，利用 GEC 互信息筛选更容易暴露模型上下文依赖的困难样本，并将其用于模型训练或鲁棒性评估，以提升模型在不同上下文中的纠错稳定性。

## 2.3 面向模型输出编辑的可解释性方法设计

可解释性部分主要围绕模型实际修改的编辑级错误分析与解释一致性校验展开。本研究

首先对“原句—模型输出—参考答案”进行编辑抽取和对齐，将模型输出拆解为具体编辑，并统计模型在正确纠正、错误纠正、漏纠和过度纠正上的表现；随后，为每处编辑生成自然语言解释，要求解释说明错误位置、修改方向、错误类型和相关语法依据；最后，采用“解释到编辑”的反向重构方法，在隐藏原始编辑的情况下，仅根据原句和解释反推出应修改的位置、修改内容和错误类型，并与模型实际编辑进行比较，以判断解释是否存在错位、泛化或语法依据不准确等问题。

## 2.4 实验评估与结果分析

选取序列到序列、序列到编辑和大语言模型等代表性 GEC 方法作为实验对象，在标准测试集、上下文反事实样本和增强训练数据上进行实验。通过对比实验、消融实验和案例分析，分别评估模型的纠错准确性、上下文稳定性、编辑级错误分析结果和解释一致性，验证上下文反事实样本和解释一致性校验方法的有效性。

# 三、实验方案

## 3.1 数据集与实验设置

实验拟采用 CoNLL-2014、BEA-2019、TEM-8 等 GEC 数据集作为标准评测数据，并基于 CoCoGEC 构造对应的上下文反事实样本。反事实样本包括句内扰动样本和句间上下文扩展样本，用于模拟真实写作中错误无关上下文变化的情况。实验将在统一的数据划分、模型设置和推理参数下进行，保证不同模型和不同方法之间的结果可比较。

## 3.2 对比模型与训练设置

选取三类代表性 GEC 模型进行实验：（1）序列到序列模型，如 T5、BART 等生成式纠错模型；（2）序列到编辑模型，如 GECToR 等编辑式纠错模型；（3）大语言模型方法，如基于提示的开源或闭源 LLM 纠错方法。在训练设置上，分别比较原始训练数据、通用数据增强样本和 CoCoGEC 反事实增强样本对模型性能的影响。对于不进行微调的大语言模型，主要通过统一提示模板进行推理比较；对于可训练模型，则比较增强前后在标准样本和反事实样本上的表现变化。

## 3.3 鲁棒性实验

鲁棒性实验主要考察模型在上下文变化前后是否保持一致纠错。实验将比较原句和反事实变体上的模型输出，分析不同扰动方式、上下文长度和错误类型对模型的影响。评价指标包括标准纠错性能 F0.5、预测一致性、编辑保持率和扰动前后性能变化等。通过这些指标判断模型是否会因为错误无关上下文变化而产生不一致修改。

## 3.4 可解释性实验

可解释性实验主要考察模型实际修改能否被分析，以及生成解释是否真正对应具体修改。本研究首先对“原句—模型输出—参考答案”进行编辑抽取和对齐，将模型输出拆解为具体



编辑，并统计模型在正确纠正、错误纠正、漏纠和过度纠正上的表现；随后，为每处编辑生成自然语言解释，要求解释说明错误位置、修改方向、错误类型和相关语法依据；最后，采用“解释到编辑”的反向重构方法，在隐藏原始编辑的情况下，仅根据原句和解释反推出应修改的位置、修改内容和错误类型，并与模型实际编辑进行比较，以判断解释是否存在错位、泛化或语法依据不准确等问题。对比方法包括直接整句解释、基于编辑提示的解释，以及本文提出的编辑级解释生成与反向重构校验方法。

### 3.5 评估指标、消融实验与案例分析

纠错性能采用 Precision、Recall 和 F0.5 进行评价；鲁棒性采用预测一致性、编辑保持率和性能波动进行评价；编辑级错误分析采用正确纠正率、错误纠正率、漏纠率和过度纠正率进行评价；解释质量采用解释覆盖率、位置一致性、修改方向一致性、错误类型一致性和反向重构准确率进行评价。消融实验将分别移除句内反事实、句间反事实、编辑一致性过滤、困难样本筛选和反向重构校验等模块，分析各部分对整体效果的影响。最后，选取典型样本进行案例分析，展示模型在上下文扰动下的错误变化，以及解释错位、解释泛化或语法依据不准确等问题。

## 四、可行性分析

### 4.1 研究基础较为扎实

反事实学习、数据增强、编辑级错误分析和自然语言解释生成已形成较成熟的理论与方法基础，相关研究为 GEC 的鲁棒性分析和可解释性研究提供了任务定义、数据资源和评价参考。同时，本研究具备语法纠错数据处理、反事实样本构造、模型训练和实验评价方面的研究积累，已有 CoCoGEC 相关工作作为鲁棒性分支提供了直接基础。

### 4.2 实施条件较为完备

RobustGEC、BEA-19、CoNLL-14、TEM-8、GEE、EXPECT 等英文数据资源以及 ERRANT、CLEME2.0 等评价工具均可获得，能够满足模型训练、编辑提取、编辑分析、解释生成和效果评价的需要。鲁棒性研究和可解释性研究可按数据构建、模型实现和实验验证分阶段开展，并通过参数高效微调、样本筛选和调用开源或闭源大语言模型控制计算成本，整体方案具有较好的可操作性。

### 4.3 评价方案具有可验证性

本研究提出的解释一致性并非仅依赖人工主观打分，而是通过反向编辑重构将自然语言解释转化为可比较的结构化编辑，再与模型实际编辑进行位置、方向和类型层面的匹配。这一设计使解释忠实性能够被自动化度量，并可通过人工标注样本进一步验证，具有较强的实验可检验性。

#### 4、选题的创新性或应用性。Novelty or applicability of the proposed topic.

##### 一、选题的创新性

###### 1.1 面向 GEC 的上下文反事实鲁棒性方法具有创新性

不同于随机扰动或通用数据增强方法，本研究围绕 GEC 任务中“错误不变、正确改法不变、上下文变化”的特点，构造句内和句间两类上下文反事实样本。该方法在保持原始语法错误及其有效纠正方式不变的前提下，对错误无关的词语、短语和句间上下文进行受控修改，用于分析模型是否会因无关上下文变化而产生不一致纠错结果，为 GEC 鲁棒性研究提供了更贴近任务特点的样本构造思路。

###### 1.2 融合编辑一致性过滤与困难样本筛选的鲁棒性优化机制具有创新性

本研究在反事实样本生成后，引入编辑一致性约束，过滤引入新错误、消除原错误或改变纠正方式的无效样本，保证反事实样本的标签有效性。同时，利用 GEC 互信息筛选能够暴露模型上下文依赖的困难样本，避免简单样本或噪声样本对训练造成干扰。该机制能够更有针对性地提升模型在错误无关上下文变化下的纠错稳定性。

###### 1.3 面向模型输出编辑的编辑级错误分析与解释一致性校验具有创新性

现有 GEC 评价多依赖 F0.5 等整体指标，难以说明模型具体在哪些位置改对、改错、漏改或过度纠错。本研究将模型输出拆解为具体编辑，逐条分析其修改结果和错误类型，并为每处编辑生成自然语言解释。进一步地，本研究提出“解释到编辑”的反向重构校验方法，通过检查解释能否反推出对应编辑的位置、修改方向和错误类型，判断解释是否真正对应模型实际修改，从而减少解释错位、解释泛化和语法依据不准确等问题。

##### 二、选题的应用性

###### 2.1 提升英文写作辅助与文本校对系统的可用性

本研究能够降低 GEC 系统因上下文变化而产生不稳定修改的风险，使系统在真实英文写作、办公文本校对和自动作文评价等场景中给出更稳定的纠错结果。同时，编辑级解释能够帮助用户理解每处修改的原因和依据，提升修改建议的可理解性与可追溯性。

###### 2.2 支持 GEC 模型分析、评测与质量改进

本研究形成的上下文反事实样本、编辑级错误分析结果和解释一致性校验指标，可用于发现模型的上下文敏感、漏纠误纠、过度纠错和解释不一致等问题，为不同 GEC 模型的对比评测、版本回归、错误分析和后续优化提供更细粒度的依据。

## 5、论文大纲。Proposed thesis outline.

摘要

Abstract

### 第一章 绪论

- 1.1 研究背景与意义
- 1.2 国内外研究现状
  - 1.2.1 语法错误纠正研究现状
  - 1.2.2 GEC 鲁棒性与上下文扰动研究现状
  - 1.2.3 可解释 GEC 与编辑级错误分析研究现状
- 1.3 本文的研究内容
- 1.4 本文的组织结构

### 第二章 相关概念及研究基础

- 2.1 语法错误纠正任务定义
- 2.2 GEC 主流建模方法、数据集与评价指标
- 2.3 上下文鲁棒性与反事实数据生成
- 2.4 编辑级可解释评价与自然语言解释生成
- 2.5 本章小结

### 第三章 基于上下文变化的 GEC 鲁棒性评估与反事实样本构建

- 3.1 引言
- 3.2 上下文扰动下的 GEC 问题分析
  - 3.2.1 错误无关上下文定义
  - 3.2.2 句内与句间上下文变化类型
  - 3.2.3 模型准确性与鲁棒性评价指标
- 3.3 CoCoGEC 反事实生成方法
  - 3.3.1 句内错误无关跨度改写
  - 3.3.2 句间上下文扩展生成
  - 3.3.3 编辑一致性过滤
- 3.4 反事实样本筛选与数据增强
  - 3.4.1 GEC 互信息评分
  - 3.4.2 样本质量控制
  - 3.4.3 训练数据构建
- 3.5 实验设置与结果分析
  - 3.5.1 实验设置
  - 3.5.2 与基线的对比分析
  - 3.5.3 消融实验

### 3.5.4 错误类型分析

## 3.6 本章小结

# 第四章 基于编辑级错误分析与反向编辑重构的 GEC 可解释性方法

## 4.1 引言

## 4.2 任务定义与总体框架

### 4.2.1 编辑级可解释性

### 4.2.2 解释一致性校验

### 4.2.3 总体流程与评价指标

## 4.3 面向模型输出编辑的可解释评价数据构建

### 4.3.1 预测编辑与参考编辑的自动抽取和对齐标注

### 4.3.2 编辑操作、错误类型与上下文证据标注

### 4.3.3 编辑级可解释评价样本构建

## 4.4 编辑级纠错行为分析

### 4.4.1 纠错行为类别定义

### 4.4.2 正确纠正、错误纠正、漏纠与过度纠正识别

### 4.4.3 面向错误类型的模型行为分析

## 4.5 编辑级纠错解释生成

### 4.5.1 编辑信息与上下文证据构造

### 4.5.2 面向不同纠错行为的解释生成方法

### 4.5.3 多候选解释与结构化输出设计

## 4.6 解释一致性评估

### 4.6.1 反向编辑重构任务定义

### 4.6.2 编辑位置一致性校验

### 4.6.3 修改方向与错误类型一致性校验

### 4.6.4 负例拒绝测试与解释候选重排序

## 4.7 实验设置与结果分析

### 4.7.1 实验数据集与基线方法

### 4.7.2 编辑级错误分析与解释一致性评价指标

### 4.7.3 对比实验与消融实验

### 4.7.4 人工评价与案例分析

## 4.8 本章小结

# 第五章 总结与展望

## 5.1 本文工作总结

## 5.2 主要研究结论

## 5.3 研究局限

5.4 未来展望

参考文献

6、研究计划进度、预期成果。Research schedule and expected outcomes.

一、研究计划进度

2026 年 6 月—2026 年 7 月：完善文献调研，明确整体研究问题，完成开题报告及开题答辩。

2026 年 7 月—2026 年 9 月：整理 CoCoGEC 鲁棒性研究内容，完善反事实样本构造。

2026 年 9 月—2026 年 11 月：完成鲁棒性主实验、对比实验和消融分析，整理实验结果。

2026 年 11 月—2026 年 12 月：完成编辑级错误分析模块。

2026 年 12 月—2027 年 1 月：复现编辑级解释基线，完成编辑级解释生成方法。

2027 年 1 月—2027 年 2 月：完成基于反向编辑重构的解释一致性校验相关实验。

2027 年 2 月—2027 年 3 月：整合鲁棒性与可解释性两部分研究内容，完成学位论文初稿。

2027 年 3 月—2027 年 4 月：根据导师意见补充实验并修改论文，完成预答辩和论文定稿。

2027 年 4 月—2027 年 5 月：准备论文送审与答辩材料，完成学位论文正式答辩。

二、预期成果

完成硕士学位论文《面向语法纠错的可解释性与鲁棒性优化研究》，形成上下文鲁棒性与编辑级解释相关的实验方法、代码和分析结果。

7、与本课题有关的工作积累、已有的研究工作成绩。

Prior research foundation and existing accomplishments related to the topic.

**(1) 发表论文**

CoCoGEC: Counterfactual Generation for Robust Grammatical Error Correction

(第一作者, ACL 2026 Findings)

CFL-KG: A Knowledge Graph for Instructional Support in Chinese as a Foreign Language

(第二作者, KDD 2026 AIED)

Learning from Non-Gold Pages- Multi-Positive Supervision for Visual Document Retrieval

(第二作者, EMNLP 2026 在投)

**(2) 参与竞赛**

2024.10 “华为杯”第六届中国研究生人工智能创新大赛 “一等奖”

2024.11 第二届“天翼云杯”上海市大学生云计算应用大赛赛道决赛 “三等奖”

2024.12 CCF 中国数字金融大会 Graph RAG 赛题 “冠军”

**(3) 组织竞赛**

参与 Visual Chinese Grammatical Error Correction 提案撰写与组织工作, 相关 proposal 已提交至 AACL Workshop, 本人为核心组织者。

本人承诺: 开题报告中的内容真实无误, 若有不实, 愿承担相应的责任和后果。

I hereby declare that the information provided in this form is accurate and valid, and I understand that I shall bear full responsibility for any consequences arising from false or misleading statements.

学生签字 Signature of student:

日期 Date: